

¿Cómo armé mi árbol ID3 en Excel?

 **Dataset:** 150 Flores Iris

 **Algoritmo:** Árbol de Decisión ID3

 **Resultado:** 98% de puntería

1. ¿Cómo entiendo y aplico el algoritmo ID3?

Para este trabajo, la meta que me propuse fue muy directa: tenía enfrente 150 flores revueltas pertenecientes a 3 especies distintas, y necesitaba encontrar las preguntas exactas sobre sus medidas para separarlas de la forma más limpia posible en grupitos homogéneos.

Para no andar adivinando cuál medida evaluar primero, me apoyé en dos fórmulas matemáticas esenciales:

CONCEPTO 1: ENTROPÍA (MI MEDIDA DE DESORDEN O MEZCLA)

$$H(S) = - \sum p_i \cdot \log_2(p_i)$$

La usé para calcular qué tan revueltas estaban las flores en cada paso. Si en un grupo tengo flores de todas las especies, mi entropía es alta; pero en cuanto logro aislar una sola especie pura, la entropía cae a **cero**.

CONCEPTO 2: GANANCIA DE INFORMACIÓN (GAIN)

Ganancia = Desorden que tenía – Desorden que me sobra

Con esto medí cuánta incertidumbre logré eliminar al filtrar por cada característica. La columna que me dio la ganancia más alta fue la que elegí para abrir la siguiente rama de mi árbol.

2. ¿Cómo estructuré mi libro de Excel?

Para mantener todo ordenado y completamente automatizado, diseñé mi archivo **IrisID3_204164.xlsx** en 3 hojas de cálculo conectadas entre sí:

Hoja	¿Qué función le di?	¿Qué coloqué adentro?
1. Rangos	Mis reglas de corte	Aquí definí los límites numéricos (usando percentiles) para transformar las medidas en categorías: chico, mediano o grande.
2. Datos	Mi tabla con las 150 flores	Cargué las medidas originales en centímetros y, mediante fórmulas condicionales SI (), las convertí automáticamente a texto según los rangos establecidos.
3. Calculos_ID3	El motor de cálculo	Aquí armé las tablas de frecuencias, calculé las probabilidades, las entropías y las ganancias en cada nivel hasta obtener las reglas finales de clasificación.

3. Paso 1: Convertí las medidas continuas a categorías

Como el algoritmo ID3 tradicional trabaja con valores discretos y no con números continuos, lo primero que hice fue dividir las medidas de las flores en 3 partes equilibradas (33.3% y 66.7%):

Medida de la Flor	Mínimo	Corte Chico (≤ 33.3%)	Corte Mediano (≤ 66.7%)	Máximo	Rangos que definí
Sepal Length (Largo sépalo)	4.3 cm	≤ 5.4 cm	≤ 6.3 cm	7.9 cm	Chico ≤ 5.4 Mediano ≤ 6.3 Grande > 6.3
Sepal Width (Ancho sépalo)	2.0 cm	≤ 2.9 cm	≤ 3.2 cm	4.4 cm	Chico ≤ 2.9 Mediano ≤ 3.2 Grande > 3.2
Petal Length (Largo pétalo)	1.0 cm	≤ 2.4 cm	≤ 4.9 cm	6.9 cm	Chico ≤ 2.4 Mediano ≤ 4.9 Grande > 4.9
Petal Width (Ancho pétalo)	0.1 cm	≤ 0.8 cm	≤ 1.6 cm	2.5 cm	Chico ≤ 0.8 Mediano ≤ 1.6 Grande > 1.6

Para no tener que etiquetar a mano las 150 filas, apliqué en mi hoja **Datos** esta fórmula referenciando a mi hoja de rangos:

```
=IF(A2<=Rangos!$C$2, "chico", IF(A2<=Rangos!$D$2, "mediano", "grande"))
```

4. Paso 2: Escogí la variable raíz de mi árbol

Al inicio tenía las 150 flores repartidas de manera equitativa: 50 Setosa, 50 Versicolor y 50 Virginica (33.3% cada una). El desorden total inicial de mi base fue:

Desorden inicial = $\log_2(3) \approx 1.5850$ bits

Para saber con cuál variable debía empezar mi árbol, evalué en **Calculos_ID3** la ganancia de cada una:

Variable que puse a prueba	Desorden inicial	Desorden sobrante	Ganancia que obtuve (Gain)	Mi decisión
Petal Width (Ancho del pétalo)	1.5850	0.2156	1.3694 bits	GANA Y QUEDA COMO RAÍZ
Petal Length (Largo del pétalo)	1.5850	0.2604	1.3246 bits	Descartada
Sepal Length (Largo del sépalo)	1.5850	0.9380	0.6470 bits	Descartada
Sepal Width (Ancho del sépalo)	1.5850	1.2366	0.3484 bits	Descartada

¿Qué descubrí al filtrar por Petal Width?

- **Chico (50 flores):** Me cayeron las 50 *Setosa* y ninguna otra flor. Entropía = 0. Esta rama me quedó 100% pura y la cerré directamente como hoja *Iris-setosa*.
- **Mediano (52 flores):** Me quedaron 48 *Versicolor* y 4 *Virginica* (desorden = 0.3912). Necesité desempatar.
- **Grande (48 flores):** Me quedaron 2 *Versicolor* y 46 *Virginica* (desorden = 0.2499). También requerí desempatar.

5. Paso 3: Abrí la rama de Petal Width = Mediano

Tomé únicamente a las 52 flores que cayeron en la categoría "mediano" y puse a competir a las 3 variables que me quedaban para ver cuál las clasificaba mejor:

Variable que probé	Desorden de partida	Desorden sobrante	Ganancia que conseguí	Mi decisión
Petal Length	0.3912	0.0694	0.3218 bits	GANA ESTE NODO
Sepal Length	0.3912	0.3770	0.0142 bits	Descartada
Sepal Width	0.3912	0.3867	0.0045 bits	Descartada

¿Cómo me resolvió Petal Length en este grupo?

- Cuando **Petal Length fue mediano** (47 flores): Las 47 resultaron *Versicolor* puras (100% de certeza). La definí como hoja *Iris-versicolor*.
- Cuando **Petal Length fue grande** (5 flores): Quedaron 4 *Virginica* y 1 *Versicolor*. Por criterio de mayoría (80%), la asigné a *Iris-virginica*.

6. Paso 4: Abrí la rama de Petal Width = Grande


Hice exactamente lo mismo con las 48 flores del grupo "grande" (compuesto por 2 *Versicolor* y 46 *Virginica*) para encontrar la variable que mejor las ordenara:

Variable que probé	Desorden de partida	Desorden sobrante	Ganancia que conseguí	Mi decisión
Sepal Width	0.2499	0.2014	0.0485 bits	GANA ESTE NODO
Petal Length	0.2499	0.2277	0.0222 bits	Descartada
Sepal Length	0.2499	0.2453	0.0046 bits	Descartada

¿Cómo me resolvió Sepal Width aquí?

- Con **Sepal Width chico** (18 flores): Las 18 resultaron *Virginica* puras (100%).
- Con **Sepal Width mediano** (22 flores): Quedaron 20 *Virginica* y 2 *Versicolor*. Con el 90.9% de los casos ganó por mayoría *Iris-virginica*.
- Con **Sepal Width grande** (8 flores): Las 8 resultaron *Virginica* puras (100%).

7. El esquema del árbol que obtuve



8. Las 6 Reglas finales que dejé listas

Para finalizar, sintetice todo el árbol en esta tabla de 6 reglas directas:

Regla	Condición 1	Condición 2	Flores que entraron	Especie que predigo	Certeza
Regla 1	Petal Width = chico	-	50	Iris-setosa	50 de 50 (100% seguro)
Regla 2	Petal Width = mediano	Petal Length = mediano	47	Iris-versicolor	47 de 47 (100% seguro)
Regla 3	Petal Width = mediano	Petal Length = grande	5	Iris-virginica	4 de 5 (gana por mayoría)
Regla 4	Petal Width = grande	Sepal Width = chico	18	Iris-virginica	18 de 18 (100% seguro)
Regla 5	Petal Width = grande	Sepal Width = mediano	22	Iris-virginica	20 de 22 (gana por mayoría)
Regla 6	Petal Width = grande	Sepal Width = grande	8	Iris-virginica	8 de 8 (100% seguro)

9. Mis resultados y conclusiones

Al verificar los resultados de mi clasificación contra las especies reales obtuve lo siguiente:

- **Flores bien clasificadas:** 50 (Setosa) + 47 (Versicolor en R2) + 4 (Virginica en R3) + 18 (Virginica en R4) + 20 (Virginica en R5) + 8 (Virginica en R6) = **147 flores correctas**.
- **Flores donde falló:** Únicamente 3 flores Versicolor que se me mezclaron en ramas donde ganó Virginica por mayoría.
- **Efectividad total alcanzada:** $147 / 150 = 98.0\%$ de puntería.

Conclusión personal: Logré construir un clasificador ID3 completamente funcional y transparente en Excel. Comprobé que sin necesidad de programar scripts externos, simplemente aplicando las fórmulas de logaritmo base 2 y organizando bien las tablas lógicas, se puede alcanzar un 98% de precisión en el dataset Iris.